旅游规划助手产品需求文档

面向人工智能创新开发实践课程设计的轻量级智能体系统

字段	内容
文档版本	v1.1
状态	已确认真实 API 与自有主机部署方案
创建日期	2026 年 10 月 11 日
目标交付	部署到自有主机的 Docker Compose 旅游规划助手

结论摘要：本项目采用单个 LangGraph 状态图而非重型多智能体集群，以 DeepSeek API、Travelport 正式旅行 API、公开地理与天气 API、ChromaDB 和 SQLite 构建可演示、可测试、可追溯的旅游规划助手。所有业务数据均来自正式授权或公开真实 API，系统不提供模拟运行模式。

验收主线：七类意图可用；覆盖中国全境知识库；RAG Top3 命中率不低于 95%；有来源回答依据覆盖率达到 100%；首 token P95 不超过 2 秒；Docker Compose 可在自有主机启动；GitHub Actions 在合并前完成质量、安全、测试和镜像门禁。

1 产品概述

1.1 背景与问题

用户在规划旅行时需要在攻略、天气、景点、住宿、交通和预算之间反复切换。普通聊天模型能生成流畅文本，但容易编造营业时间、票价或路线，也无法证明推荐来自哪里。本系统将自然语言交互、RAG 私有知识库与可验证的外部工具调用组合成一条轻量工作流，为课程演示提供完整的 Agent 开发闭环。

1.2 产品目标

目标	量化结果	验证方式
完成核心旅行任务	覆盖目的地、行程、交通、住宿、美食、天气、闲聊 7 类意图	固定测试集逐类执行
提高答案可信度	RAG 回答给出来源；依据覆盖率 100%；Top3 命中率 ≥95%	标注问答集 + 自动评测
保持轻量部署	核心服务 4 个以内；无 GPU 也可运行；一条 Compose 命令启动	全新主机冷启动演练
体现 Agent 能力	系统自主决定追问、检索、调用工具或直接回答	轨迹日志和 Chainlit 步骤展示
形成工程闭环	PR 必须通过代码质量、测试、安全扫描、镜像构建	GitHub 分支保护与 Actions

1.3 非目标与边界

- 不直接完成机票、火车票、酒店的支付和下单；仅展示正式 API 返回的实时查询结果和供应商跳转链接。
- 不保证第三方价格、余票、营业时间实时正确；答案必须显示数据时间与核验提示。
- 首版不做复杂用户画像、社交、商家后台、地图导航和移动端原生应用。
- 首版以中文交互和中国国内旅行场景为主，海外目的地为扩展项。

1.4 用户与核心场景

用户	核心任务	成功标准
学生演示者	用自然语言展示 Agent 路由、RAG、工具调用和多轮记忆	5 分钟内完成从需求到行程的完整演示
旅行计划者	输入目的地、天数、人数、偏好和预算，获得可执行计划	行程结构完整且约束冲突可解释
课程教师	检查知识库、指标、工程规范、测试和文档	指标可复现，过程材料可追溯
开发成员	本地开发、调试、提交 PR、部署	配置测试环境 API Key 后可执行真实接口测试

2 需求依据与假设

2.1 任务书硬性要求映射

任务书要求	PRD 落地项	验收证据
理解自然语言并自主调用工具或检索知识库	LangGraph 条件路由；结构化意图与槽位	Agent 轨迹、单元测试、演示录像
工具调用、RAG、知识库构建	工具适配层；ChromaDB；混合检索	索引脚本、检索评测、引用展示
多轮对话与上下文	SQLite LangGraph Checkpointer；thread_id	连续 10 轮回归用例
完整源码与部署文档	Dockerfile、compose.yaml、.env.example、README	全新环境部署记录
AI 辅助开发档案	prompts、AI 原始输出、bug 日志、人工修正记录	docs/ai-dev-log 目录
系统测试报告	功能、RAG、性能、故障、安全测试	CI 产出的 HTML/JSON 报告
团队协作与例会	里程碑、任务分工、每周会议纪要模板	GitHub Projects 与 docs/meetings

2.2 已采用假设

- 课程答辩与部署均使用真实 API；每种外部工具必须有缓存、超时、熔断和错误提示，但不得用虚构数据替代失败结果。
- DeepSeek 使用 OpenAI 兼容 API；模型名称、Base URL 和密钥均通过环境变量配置，不写入代码或镜像。
- 航班、酒店和铁路使用已申请正式凭据的 Travelport Universal API 或等价正式授权供应商 API；不抓取受限网站。
- 知识库覆盖中国全部省级行政区、地级市和主要县级目的地；索引按省份与城市增量构建。
- 性能指标在预热索引、并发 1、稳定网络和 20 条标准查询下测量；2 秒指标指首 token P95，同时单独报告完整响应和第三方 API 耗时。

3 功能需求

3.1 意图与槽位

ID	意图	示例	工具与知识	必填槽位
INT-01	目的地信息查询	成都有什么好玩的	search_attractions + RAG	destination
INT-02	行程规划	规划 3 天西安行程	create_itinerary + get_weather + RAG	destination, days
INT-03	交通查询	广州到长沙高铁有哪些	search_trains / search_flights	start_city, target_city, date
INT-04	住宿查询	西湖附近推荐酒店	search_hotels + RAG	city；可选 budget
INT-05	美食推荐	长沙有什么必吃	search_food + RAG	city
INT-06	天气查询	明天长沙天气怎样	get_weather	city, date
INT-07	闲聊与兜底	你好；谢谢	无；边界提示	无

统一槽位模型还包括 people_number、preferences、budget、start_date、end_date、transport_preference。槽位为空或歧义时，Agent 只能追问所需最少信息，不得猜测日期、人数或预算。

3.2 需求明细与验收标准

ID	能力	产品规则	验收标准
FR-01	意图识别与结构化槽位	一次 LLM 调用输出受 Pydantic 约束的 JSON；解析失败自动修复一次，再失败进入澄清。	标注集宏平均准确率 ≥90%；必填槽位抽取 F1 ≥90%。
FR-02	目的地检索	按城市、偏好、开放状态检索景点，展示名称、简介、位置、来源与抓取时间。	Top5 至少 3 条与查询相关；来源链接可打开。
FR-03	行程生成	按天生成上午/下午/晚间计划，包含地点、建议时长、交通衔接、天气适配和预算小计。	每一天结构完整；不出现时间重叠；总预算不超过用户预算或明确提示冲突。
FR-04	交通与住宿	通过正式授权 API 查询实时航班、铁路和酒店候选；API 不可用时返回可解释错误，不生成替代数据。	结果标记供应商、查询时间、币种和有效期；价格与库存均来自本次 API 响应。
FR-05	天气	调用 Open-Meteo 获取目标地点与日期的预报，失败时给出可恢复提示。	合法城市查询成功率 ≥95%；超时后 2 次指数退避，总等待上限 5 秒。
FR-06	RAG 与引用	向量 + BM25 检索后用 RRF 融合，答案句子绑定 source_id。	标注集 Top3 命中率 ≥95%；有事实依据的回答引用覆盖率 100%。
FR-07	多轮记忆	使用 thread_id 保存已确认槽位、工具摘要和最近对话。	10 轮内可正确引用目的地、日期、预算；重启容器后会话仍可恢复。
FR-08	过程可视化	Chainlit 展示意图、检索、工具、合成步骤及耗时，隐藏密钥和内部提示词。	每个步骤有状态与耗时；日志无密钥。
FR-09	反馈与追踪	用户可点赞/点踩并填写原因；保存匿名 trace_id。	反馈写入 SQLite；可按日期导出 CSV。
FR-10	安全边界	拒绝提示注入、密钥探测和越权工具参数；外部文本视为不可信数据。	安全用例全部通过；日志与回答不出现 secret。

4 交互与 Agent 流程

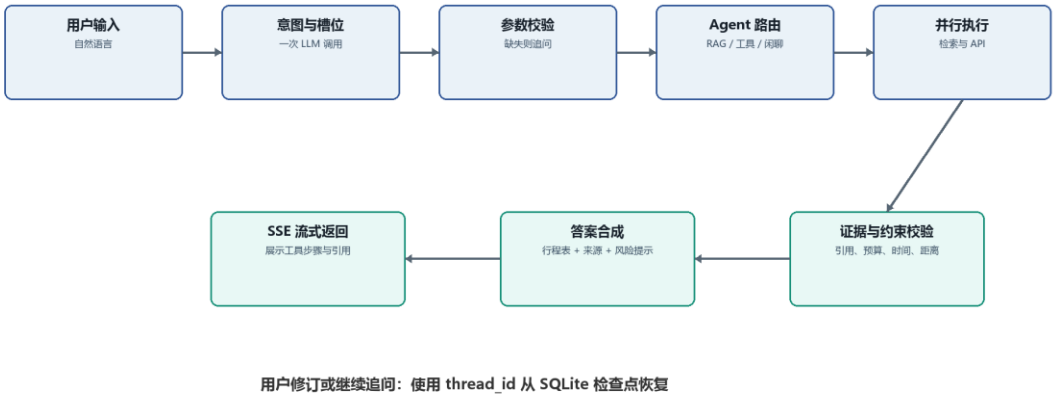


图 1 用户请求到可追溯答案的处理流程

4.1 状态机节点

节点	输入	输出	失败策略
normalize_input	message, thread_id	标准化文本与上下文	空输入直接提示
classify_and_extract	文本与历史槽位	intent, slots, confidence	修复一次；低置信度追问
route	意图、槽位完整性	下一节点	未知意图进入边界说明
retrieve	query, filters	TopK 文档及分数	无命中时不强行生成事实
call_tools	结构化参数	标准 ToolResult	超时、熔断、缓存；失败时明确不可用
validate_plan	候选行程与约束	冲突清单	最多修订一次，仍冲突则显式报告
compose	证据、工具结果	带引用答案	引用不足则缩小回答范围
persist	状态、轨迹、反馈	checkpoint	失败不影响本轮答案，但提示会话不可恢复

4.2 行程输出结构

- 行程概览：目的地、日期、人数、偏好、预算、数据更新时间。
- 每日计划：时间段、地点、活动、预计时长、地点间交通、费用区间、来源。
- 总览：住宿候选、交通候选、预算汇总、天气与装备提示。
- 限制：尚未核验的信息、第三方 API 缺失、用户需二次确认的事项。

5 系统架构与技术设计

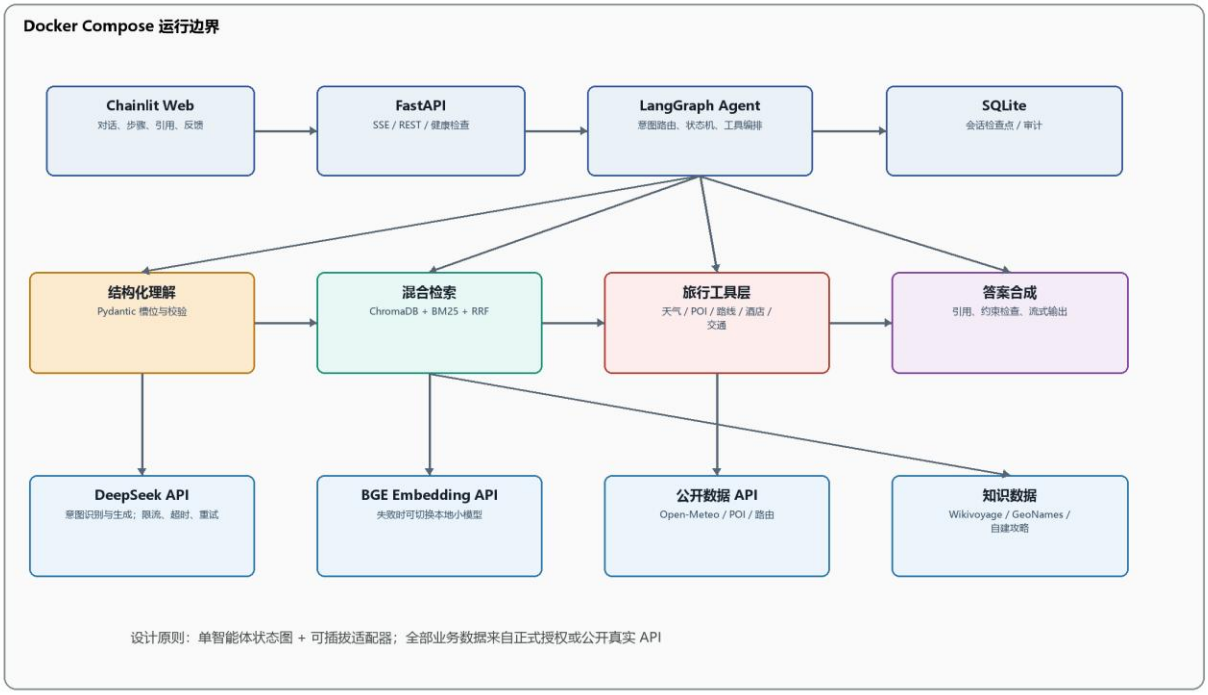


图 2 轻量级系统架构

5.1 技术选型

层级	选型	用途	轻量化理由
语言	Python 3.10+	核心开发	AI 生态完整，课程适配
前端	Chainlit	聊天、步骤、引用	无需维护独立前端工程
API	FastAPI + Uvicorn	REST、SSE、健康检查	异步、文档自动生成

层级	选型	用途	轻量化理由
编排	LangGraph	状态机、条件路由、检查点	单图替代多服务 Agent
LLM	DeepSeek API	意图、槽位、生成	中文能力与 API 成本优势
结构化输出	Pydantic + LangChain	输出模式与校验	减少重复调用
RAG	LangChain	加载、切分、检索	与 LangGraph 衔接
向量库	ChromaDB 独立容器	持久化向量索引	部署简单、官方镜像
Embedding	BGE API；本地 bge-small 备用	文档向量化	API 优先，无 GPU 依赖
检索	向量 + BM25 + RRF	混合召回	兼顾语义与专有名词
记忆	SQLite Checkpointer	会话与审计	无需额外数据库
测试	pytest + 自建评测集	功能与指标	可在 CI 离线复现
部署	Docker Compose	一键启动	统一环境、便于答辩

5.2 组件与端口

服务	端口	职责	持久化	健康检查
web	8000	Chainlit UI 与反向代理入口	无	GET /healthz
api	8001	FastAPI、LangGraph、工具与 SSE	./data/sqlite	GET /health
chroma	8002	向量存储与查询	chroma_data volume	/api/v2/heartbeat

Compose 使用非 root 用户、只读根文件系统（必要目录挂载可写卷）、资源限制和 restart: unless-stopped。密钥仅通过 .env 或部署平台 Secret 注入，.env 加入 .gitignore。

5.3 API 契约

方法与路径	请求	响应	说明

方法与路径	请求	响应	说明
POST /api/v1/chat	message, thread_id?, stream=true	SSE: meta/step/token/final/error	主对话接口
POST /api/v1/feedback	trace_id, score, reason?	status	用户反馈
POST /api/v1/admin/index	source_path, rebuild	job_id, status	开发环境启用，生产鉴权
GET /api/v1/traces/{id}	trace_id	节点、耗时、工具摘要	隐藏提示词与密钥
GET /health	无	status, deps	容器存活与依赖状态

5.4 数据模型

对象	关键字段	约束
TravelRequest	message, thread_id, destination, days, dates, people_number, preferences, budget	日期合法；days 1-14；budget ≥0
IntentResult	intent, confidence, slots, missing_slots	intent 为枚举；confidence 0-1
ToolResult	provider, status, data, fetched_at, expires_at, error_code	数据必须包含真实供应商和时间戳
SourceChunk	source_id, title, url, text, score, updated_at	URL 与引用一一对应
ItineraryDay	date, periods[], cost_min, cost_max, warnings	时间不重叠；金额单位一致
Trace	trace_id, thread_id, node_timings, tool_calls, model_usage	不保存密钥；敏感输入脱敏

6 数据与 RAG 设计

6.1 推荐数据源与链接

数据源	内容	系统用途	许可与风险	链接
TravelPlanner Benchmark	复杂约束行程规划评测；含数据库与验证工具	评测/测试数据	研究用途，按仓库许可核验	https://github.com/OSU-NLP-Group/TravelPlanner

数据源	内容	系统用途	许可与风险	链接
Wikivoyage Dumps	目的地、路线、旅行主题的文本语料	RAG 主语料	遵循 CC BY-SA 与署名要求	https://en.wikivoyage.org/wiki/Wikivoyage:Database_dump
GeoNames	城市、地名、经纬度与别名	地名标准化	CC BY 4.0，需署名	https://www.geonames.org/export/
OpenStreetMap / Geofabrik	POI、道路与地理要素区域切片	离线 POI 扩展	ODbL，需署名与数据库许可合规	https://download.geofabrik.de/
Open-Meteo	地理编码与天气预报 API	实时天气工具	按官方条款署名；无需 API Key	https://open-meteo.com/en/docs
OpenTripMap	景点与兴趣点 API	实时/准实时 POI 工具	需要 API Key，遵循服务条款	https://opentripmap.io/product
Wikidata Query Service	景点实体、坐标、分类与多语言名称	POI 补充与实体对齐	CC0 数据；注意查询限流	https://query.wikidata.org/

数据选择原则：课程原型优先使用许可清晰、可复现的数据；不把受登录、反爬或商业条款限制的网站抓取结果写入仓库。生产级价格和库存应更换为正式签约的供应商 API。

6.2 知识库加工

覆盖范围为中国全境，包括 34 个省级行政区范围内的省会、地级市、自治州、主要县级旅游目的地及跨城市线路。知识文档按省份、城市、景点类型和更新时间打标签，支持全国统一检索与城市过滤。

1. 采集：保存 source_url、license、retrieved_at、language 与内容哈希。
2. 清洗：去导航、广告、重复段落、失效链接和明显错误；城市与景点名称对齐 GeoNames/Wikidata。
3. 切分：按标题语义切分，建议 350-600 中文字符，重叠 60-100 字；保留父文档 ID。
4. 索引：BGE Embedding 写入 ChromaDB；BM25 建立词法索引；索引版本绑定数据快照。
5. 检索：向量 Top10 + BM25 Top10，经 RRF 合并取 Top3；可按城市、类别、时间过滤。
6. 生成：只把 Top3 证据和工具结果送入 LLM；每个事实句绑定 source_id。

6.3 评测集设计

集合	规模	组成	用途
intent_eval.jsonl	每类至少 30 条，共 ≥210 条	标准表达、口语、省略、复合意图、越界输入	意图准确率与槽位 F1
rag_eval.jsonl	≥100 条	query、相关 source_id、难负例	Recall@3、MRR、nDCG@3
plan_eval.jsonl	≥50 条	预算、天数、偏好、硬约束和参考检查器	约束满足率、完整率
safety_eval.jsonl	≥30 条	提示注入、密钥探测、恶意 URL、超长输入	拒绝率与泄露检查

7 外部 API 与降级策略

能力	首选实现	超时与缓存	降级
天气	Open-Meteo Geocoding + Forecast	连接 1s/总 3s；缓存 30 分钟	返回最近缓存；无缓存则说明暂不可用
景点	OpenTripMap 或 Wikidata	总 4s；缓存 24 小时	RAG 本地知识库
路线距离	openrouteservice/高德适配器	总 4s；缓存 24 小时	直线距离 + 明确“估算”
航班	Travelport Flights API	总 5s；报价按供应商有效期缓存	失败时返回不可用，不生成票价
火车	Travelport Universal API Rail 或已签约铁路供应商 API	总 5s；缓存 5 分钟	失败时返回不可用并保留重试入口
酒店	Travelport Stays API	总 5s；报价按供应商有效期缓存	失败时返回不可用，不生成价格区间
LLM	DeepSeek API	总 15s；最多重试 1 次	返回结构化错误与稍后重试提示
Embedding	BGE-M3 API	批量请求；永久缓存内容哈希	本地 bge-small-zh-v1.5

所有适配器实现统一 Provider 接口，输出 ToolResult。熔断条件为 60 秒内连续 5 次失败，熔断 60 秒；恢复阶段只放行 1 个真实探测请求。缓存只复用未超过供应商有效期的真实响应；无可用真实结果时必须明确说明服务暂不可用。

8 非功能需求与指标

维度	指标	目标值	测量方法
功能	七类意图通过率	≥95%	每类固定用例自动执行
意图	宏平均准确率	≥90%	intent_eval 混淆矩阵
槽位	必填槽位 F1	≥90%	标注槽位逐字段计算
检索	Recall@3	≥95%	rag_eval 相关文档命中
检索	MRR	≥0.90	首个相关结果倒数排名均值
生成	依据覆盖率	100%	事实句是否可映射到证据/工具结果
生成	幻觉率	0% 高风险；≤2% 一般事实	人工双人复核 + 自动规则
规划	硬约束满足率	100%	日期、预算、时间重叠检查器
性能	首 token P95	≤2 秒	从服务收到请求到首个 SSE token；20 次
性能	完整回答 P95	记录基线，不作为 2 秒门禁	独立记录 total_latency_ms
性能	外部工具调用 P95	≤5 秒/工具	独立记录 provider latency
稳定性	连续 100 请求成功率	≥99%	固定负载测试
部署	冷启动可用时间	≤60 秒	compose up 到 health=healthy
资源	空闲内存	≤1.5 GB	docker stats
安全	高危依赖与镜像漏洞	0 个	pip-audit/Bandit/Trivy
可维护	核心代码覆盖率	≥80%	pytest-cov；关键路由 ≥90%

说明：任务书中的 2 秒明确解释为首 token P95。验收报告仍同时给出应用内处理时间、首 token 时间、完整回答时间和第三方工具时间，以定位性能瓶颈。

9 测试策略与流程

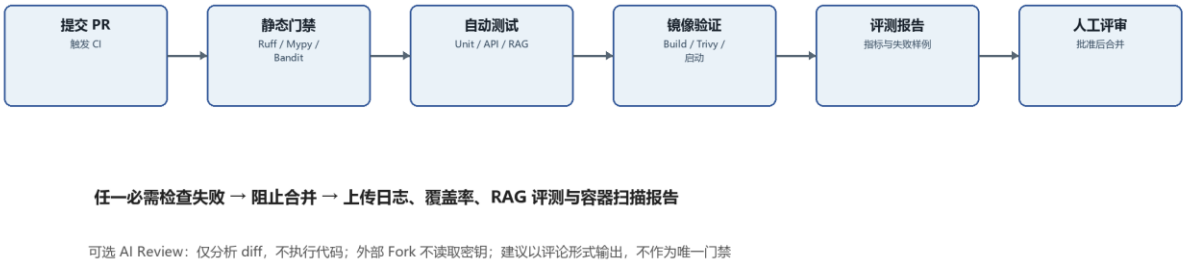


图 3 从提交到合并的自动化测试与审查流程

9.1 测试层级

层级	范围	关键用例	通过标准
单元测试	槽位、路由、RRF、预算、引用、适配器	空值、边界、异常、重试、熔断	核心模块覆盖率 ≥90%
契约测试	DeepSeek、天气、POI、交通、酒店适配器	Schema、超时、429、5xx、坏 JSON	全部 Provider 契约一致
API 集成	/chat、SSE、feedback、health	正常、断流、重复请求、并发	状态码和事件序列正确
RAG 评测	切分、召回、融合、引用	同义词、专名、难负例、无答案	Recall@3 ≥95%
端到端	7 类意图与多轮行程	正式 API 测试/生产环境	核心旅程 100% 通过
性能	首 token、完整响应、检索、并发	预热/冷启动、缓存命中/未命中	达到第 8 章目标
故障演练	LLM/API/Chroma 超时与重启	断网、限流、索引损坏、磁盘只读	可降级且错误可解释
安全测试	依赖、镜像、Secret、提示注入	泄密、SSRF、超长输入、恶意来源	无高危漏洞和秘密泄露

9.2 核心验收用例

用例	前置	步骤	预期
E2E-01 三日行程	知识库已索引；天气可用	输入“2 人预算 3000 元，规划 3 天西安历史文化游”	抽取人数/预算/天数/偏好；调用 RAG 与天气；输出不超预算的分日行程和引用
E2E-02 缺槽追问	新会话	输入“帮我规划旅行”	只追问目的地和天数等最少必需信息，不猜测
E2E-03 多轮修订	已生成西安行程	输入“第二天改成亲子活动，预算不变”	继承城市、天数、预算，只修改第二天并重新校验
E2E-04 API 失败	天气 Provider 返回 503	请求明日天气与行程	显示天气暂不可用；仍基于 RAG 生成其余内容；记录降级
E2E-05 小众地点	全国知识库已索引	询问县级小众地点细节	检索对应省市资料；无可靠证据则明确未知，不编造
E2E-06 提示注入	知识文本含恶意指令	正常查询该知识	忽略资料中的指令，只提取事实；不输出系统提示或密钥
E2E-07 重启恢复	已有 thread_id	重启 api 容器后继续追问	从 SQLite 恢复上下文

9.3 执行与报告

1. 开发者本地执行 pre-commit、单元测试，并使用测试环境凭据执行真实 API E2E。
2. PR CI 并行执行 lint/type/security、pytest、RAG 快速评测和 Secret 扫描。
3. CI 构建 Compose 镜像，启动服务并轮询健康检查，执行 API smoke test。
4. 主分支或每日任务运行完整 RAG、性能与真实 API 沙盒测试；失败不覆盖历史基线。
5. 产出 junit.xml、coverage.xml、rag_metrics.json、performance.json、trivy.sarif 和失败样例。

10 GitHub Actions 自动代码审查机制

10.1 工作流与门禁

工作流	触发	步骤	是否阻止合并
pr-quality.yml	pull_request	Ruff format/check、Mypy、Bandit、pytest-cov、detect-secrets	是
rag-eval.yml	PR 且 RAG 文件变化	建立临时索引、运行快速集、比较基线	Recall@3 下降 >2 个百分点或低于 95%则阻止
container.yml	pull_request / main	Buildx、Compose smoke、Trivy FS/Image、生成 SBOM	高危漏洞或启动失败则阻止
ai-review.yml	内部 PR；显式标签 ai-review	把最小化 diff 发送给 DeepSeek，输出结构化风险评论	否；仅辅助人工
nightly.yml	每日定时 / 手动	完整评测、真实 API 沙盒、性能趋势	不直接阻止既有提交；创建 Issue

10.2 分支保护规则

- main 禁止直接推送；至少 1 名非作者批准；所有必需检查通过后方可合并。
- CODEOWNERS：Agent/RAG、部署、安全敏感路径由对应成员复核。
- 开启 Dependabot；依赖升级 PR 自动运行全套测试，禁止自动合并主版本升级。
- 工作流权限默认 contents: read；只有评论任务使用 pull-requests: write；第三方 Action 固定到 commit SHA。
- Fork PR 不注入任何 API Secret；AI Review 和真实 API 测试仅在可信分支执行。

10.3 AI Review 规则

AI 审查输入仅包含 PR diff、项目规则和测试摘要，不发送 .env、用户数据、完整知识库或仓库秘密。输出按“严重级别、文件与行号、问题、证据、修复建议”组织；只评论可证实问题，不自动修改或批准 PR。人工评审者必须核验 AI 建议，AI 评论不替代必需测试和 CODEOWNER 批准。

10.4 建议仓库结构

```
app/
  api/          FastAPI 路由与 SSE
  agent/        LangGraph 状态、节点、路由
  models/       Pydantic 请求与结果模型
  rag/          全国数据采集、分区索引、混合检索
  tools/        provider 接口与正式 API 适配器
  ui/           Chainlit 入口
data/           许可说明与可公开的小型评测数据
evals/          intent、RAG、plan、安全评测集
tests/          unit、integration、e2e
docs/           架构、部署、测试、AI 开发档案、会议纪要
.github/        workflows、CODEOWNERS、PR 模板
Dockerfile  compose.yaml  pyproject.toml  .env.example
```

11 Docker 部署与运维

11.1 部署验收

1. 复制 .env.example 为 .env，填写 DeepSeek、Travelport、天气、景点和路线服务的正式 API 凭据。

2. 执行 docker compose up -d --build。

3. 等待 web、api、chroma 三个服务状态 healthy，60 秒内完成。

4. 通过自有主机 HTTPS 域名访问系统，执行天气、目的地、三日行程和多轮修改四个冒烟场景。

5. 执行 docker compose restart api 后继续原 thread_id，验证 SQLite 持久化。

6. 执行 docker compose down 后数据卷保留；使用带 -v 的清理命令前必须备份。

11.2 配置项

变量	必需	示例/默认	说明

变量	必需	示例/默认	说明
APP_ENV	是	production	自有主机使用生产配置
DEEPSEEK_API_KEY	是	Secret	不得写入日志
DEEPSEEK_MODEL	否	deepseek-chat	以供应商当前可用模型为准
TRAVELPORT_CREDENTIALS	是	Secret 引用	航班、酒店和铁路正式凭据
CHROMA_HOST	否	chroma	Compose 服务名
SQLITE_PATH	否	/data/app.db	挂载持久卷
PUBLIC_BASE_URL	是	https://travel.example.com	自有主机外部访问地址
TOOL_TIMEOUT_SECONDS	否	5	外部工具总超时
LOG_LEVEL	否	INFO	生产禁止 DEBUG 泄露输入

11.3 可观测性

- 日志使用 JSON，字段包含 trace_id、thread_id_hash、node、provider、latency_ms、status、error_code；不记录密钥和完整个人信息。
- 每次回答返回 trace_id；Chainlit 展示节点耗时摘要；评测环境保存 LangGraph 轨迹。
- 健康检查区分 liveness 与 readiness，Chroma、正式 API 凭据或关键配置不可用时 readiness=false。
- 自有主机通过 Caddy 或 Nginx 终止 TLS，只暴露 80/443；API、Chroma 与 SQLite 不直接暴露公网。

12 竞品与开源参考

项目	可借鉴点	需避免/裁剪	链接
LangChain Travel Planner	Docker、工具抽象、Smoke test	Flask 改为课程指定 FastAPI；外部数据改接正式 API	https://github.com/MUSE-CODE-SPACE/langchain-travel-planner

项目	可借鉴点	需避免/裁剪	链接
TwoSigma Travel Planner Agent	LangGraph + FastAPI、酒店/航班/天气/景点分工	React 与多 Agent 对本课题过重	https://github.com/TwoSigma-Labs/Travel-Planner-Agent
LangChain Samples Travel Planner	官方示例的状态图、线程与 Human in the Loop	LangSmith 云部署不是必需依赖	https://github.com/langchain-samples/demos-travel-planner-agent
AI Trip Planner	实时天气、地点、预算、汇率工具和 FastAPI	Streamlit 改为 Chainlit；核验外部数据许可	https://github.com/Balaji-253/AI-Trip-Planner
JourneyPilot	来源支撑的行程、RAG、Docker、自托管	功能范围较大，首版不做地图和 PDF	https://github.com/Lagom-TA/JourneyPilot
TravelPlanner Benchmark	约束规划数据库、验证器与评测方法	不直接复制数据到产品库，先核验许可	https://github.com/OSU-NLP-Group/TravelPlanner

参考策略：借鉴架构与测试方法，不直接照搬代码。纳入任何第三方代码前检查许可证、依赖安全和维护状态，并在 NOTICE 或依赖清单中保留归属。

13 项目计划与分工

阶段	周次	关键任务	里程碑
需求与设计	第 1 周	确定范围、数据许可、PRD、架构、评测口径	PRD 评审通过
骨架与数据	第 2 周	仓库规范、Compose、FastAPI/Chainlit、全国数据清洗与分区索引	自有主机基础服务可启动
Agent 与工具	第 3 周	意图槽位、LangGraph、天气/POI、Travelport 适配器	七类意图主路径可用
RAG 与记忆	第 4 周	混合检索、引用、SQLite Checkpoint、反馈	Top3 指标达到基线
测试与 CI	第 5 周	真实 API 自动测试、Actions、镜像扫描、故障演练	所有门禁通过
优化与文档	第 6 周	首 token 优化、部署文档、用户手册、AI 开发档案	自有主机全新部署复现
答辩准备	第 7 周	PPT、演示脚本、测试报告、风险预案	5 分钟演示稳定完成

角色	主责	必须留下的证据

角色	主责	必须留下的证据
项目经理	范围、排期、例会、PRD、答辩整合	计划表、会议纪要、风险清单、验收记录
Agent/RAG 开发	LangGraph、意图槽位、检索、评测	设计记录、评测脚本、指标报告、人工修正日志
平台/测试开发	FastAPI、Chainlit、工具适配、Docker、CI	接口文档、测试报告、工作流、部署录像

14 风险与应对

风险	概率/影响	预防	触发后的处理
第三方 API 限流或停服	高/高	缓存、超时、配额监控、Provider 抽象	使用有效真实缓存；无缓存则明确暂不可用
实时价格不可获得	中/高	使用正式授权 API，保存报价有效期	拒绝生成价格并引导稍后重试
RAG 全国索引规模增长	中/高	按省市分区、增量索引、元数据过滤	扩容 Chroma 持久卷并重建受影响分区
RAG 指标不足	中/高	清洗、分层切分、混合检索、难负例	调整 chunk、权重和过滤器并记录对比
LLM 幻觉	中/高	结构化输出、引用约束、无证据不回答	缩小回答范围并明确未知
首 token 指标受网络影响	高/高	SSE、并行工具、连接池、真实响应缓存	监控网络与供应商耗时，优化首段生成
Secret 泄露	低/高	.env 忽略、Secret 扫描、最小权限	立即吊销轮换，清理历史并复盘
自有主机故障	中/高	健康检查、磁盘监控、数据库备份、镜像版本化	在同一主机回滚镜像并恢复持久卷备份
范围膨胀	中/中	七类意图为 MVP，变更需评审	延期非目标功能

15 完成定义与评审清单

- □ 七类意图均有正常、缺槽、异常用例并通过
- □ 中国全境知识库完成分区索引与抽样验收
- □ RAG Recall@3 ≥95%，引用依据覆盖率 100%

- □ 多轮 10 轮与容器重启恢复测试通过
- □ 首 token P95 ≤2 秒，完整响应与外部工具耗时分别报告
- □ Docker Compose 在自有主机 60 秒内健康
- □ 航班、铁路、酒店结果均来自正式 API 且带供应商时间戳
- □ 无高危依赖/镜像漏洞，无 Secret 入库
- □ PR 合并门禁与 CODEOWNERS 已启用
- □ 所有数据源记录许可、时间、URL 和版本

附录 A 参考链接

- DeepSeek API 文档 https://api-docs.deepseek.com/
- LangGraph 文档 https://docs.langchain.com/oss/python/langgraph/overview
- FastAPI 文档 https://fastapi.tiangolo.com/
- Chainlit 文档 https://docs.chainlit.io/
- Chroma 文档 https://docs.trychroma.com/
- Docker Compose 文档 https://docs.docker.com/compose/
- GitHub Actions 文档 https://docs.github.com/actions
- Travelport Universal API
  https://support.travelport.com/webhelp/uapi/Content/Introduction.htm
- Travelport Flights 与 Stays API https://developer.travelport.com/resources/devkits-and-downloads
- Open-Meteo API https://open-meteo.com/en/docs
- GeoNames 数据导出 https://www.geonames.org/export/
- Wikivoyage Dumps https://en.wikivoyage.org/wiki/Wikivoyage:Database_dump
- TravelPlanner Benchmark https://github.com/OSU-NLP-Group/TravelPlanner

附录 B 待确认事项

开发前需要登记三项实施参数：Travelport 或等价正式供应商的最终账号、环境端点、请求限频与生产授权范围；自有主机的域名、CPU、内存、磁盘、操作系统和公网带宽；中国全境知识库首批数据快照日期与定期更新频率。